

赵梵年

电话 13566980606 | 邮箱 13566980606@163.com | 六级 (448)

2002.06 · 籍贯: 浙江金华 · 2027 届硕士 · 求职方向: AI Agent



教育经历

杭州电子科技大学 · 电子信息 · 硕士

2024.06 - 2027.06

湖南科技大学 · 电子信息科学与技术 · 本科 · CET-4 / CET-6

2020.09 - 2024.06

实习经历

腾讯科技 · CSIG 云与智慧产业事业群 · Agent 开发实习生

2026.01 - 2026.04

项目背景: 腾讯内部 dw-agent CLI 为 AI Agent 提供统一的命令行交互与任务执行入口, 核心运行时 dclaw 支持多模型接入、会话与记忆管理、Skill 加载及工具调用, 支撑多步骤任务执行。

我的职责: 参与内部 dw-agent CLI 运行时组件开发, 负责 Skill 管理优化、工具动态调度及流式执行性能优化。

- Skill 目录优化:** 通过文件指纹缓存与可配置 TTL 脏检查识别目录变化, 复用技能元信息与目录摘要; 设计紧凑 Overview, 减少重复解析和无关上下文注入, 重复 Summary 平均获取耗时降低 86.9%, Available skills 提示词区域体积降低 79.93%。
- Runtime 性能优化:** 针对流式分片中的重复属性写入和历史数据复制, 采用 Chat-span 属性单次提交与 Copy-on-Write 快照共享, 降低执行链路的内存分配开销; 40-chunk Trace 基准内存由 2.17 MB/op 降至 125 KB/op; 1,024 条历史下 InvocationView 创建基准内存由 6.64 MB/op 降至 1.94 KB/op。
- 动态能力路由:** 实现 Deferred Tool / Skill Surface, 以 BM25 检索 Tool Schema 与 Skill Summary, 经 tool_search + dynamic_agent 按需向子 Agent 挂载能力, 将能力发现与任务执行分离, 控制父 Agent 的常驻上下文开销; 父 Agent 常驻工具由 21 个降至 5 个, Tool Declaration 体积降低 69.9%, Prompt Token 由 13,764 降至 6,389 (-53.6%)。

杭州华为技术有限公司 · AI 应用实习生

2025.09 - 2025.11

业务背景: 面向华为 Ascend NPU 的 MindSpore / MindNLP 生态, 开展模型应用适配与可交互案例开发, 支持 OCR 文档解析和图像生成场景。

我的职责: 开展推理流程迁移、兼容性处理与 Gradio 案例开发, 整理可复用的运行示例。

- DeepSeek-OCR:** 在 Ascend 910B 上适配 OCR 与结构化解析, 以 one-hot 加权聚合替代 scatter_add, 通过后台线程与 TextIteratorStreamer 实现流式输出; 结合 MoE 权重合并与 KV Cache, 案例记录中 Gundam 模式下解码输出速率达关闭 MoE 合并时的 4.95 倍 (2.29 → 11.34 片段/s, 按流式片段设计口径)。
- Photo2Style:** 基于 MindSpore、MindNLP 与 Diffusers 完成图生图适配, 处理依赖兼容性与设备映射; 使用 LRU 缓存复用不同风格的模型 Pipeline, 结合 Attention Slicing 控制推理内存开销; 将全图风格化与局部人脸软遮罩融合结合, 保留面部结构, 并提供 Gradio 交互界面。

杭州海康威视数字技术有限公司 · 海康机器人 · 测试开发实习生

2025.06 - 2025.08

工业视觉测试开发 | 自动化巡检与相机标定

- 测试与自动化:** 覆盖工业相机、PCIe 采集卡与 IPC 工控机的功能、兼容性和 24 小时稳定性测试; 使用 Bash / Python 周期巡检设备、驱动及内核日志, 自动汇总 error、timeout、disconnect 等异常。
- 相机标定:** 基于 OpenCV 实现棋盘角点检测、内参与畸变系数计算、重投影误差评估及畸变校正, 结合清晰度、亮度均匀性与角点稳定性验证成像质量。

项目经历

锅圈食汇 · 多 Agent 智能招聘系统 课题组横向 | 上海瀚海领航科技有限公司

2026.06 - 2026.08

项目描述: 面向企业招聘中岗位需求梳理、简历筛选与面试评估分散、人工流转较多的问题, 基于 FastAPI、React、MySQL、Redis 和 Elasticsearch 构建智能招聘系统。通过六个业务 Agent 串联 JD 撰写、候选人画像、招聘海报、简历筛选、面试出题与录用评估, 结合知识检索、阶段状态追踪及人工确认, 支持 HR 在统一工作台推进招聘流程。

- 工作流编排:** 统一 ToolInput / ToolOutput 协议, 由 Supervisor 协调六个业务 Agent; 基于岗位关键词匹配 YAML 流程规格, 未命中时由 LLM 补充规划, 形成阶段执行计划。按阶段传递岗位需求与上游产物, 管理执行状态, 并在关键节点引入人工确认, 支持 HR 审核、修改结果后继续推进招聘流程。
- 解析与筛选:** 将基础信息、工作经历、教育背景与项目经历拆为 4 个并行解析子任务并合并结构化结果, 使用信号量限制 4 路并发评分; 构建 22 维候选人画像与六维评分权重聚合, 按岗位调整评分标准, 输出分项得分、优势、风险及缺失信息, 评分失败时提示人工复核; 通过 Jaccard 相似度与 Union-Find 聚类识别重复简历。
- 检索与记忆:** 将 Wiki 知识分块同步至 Elasticsearch, 结合词法检索与向量相似度召回, 对结果进行加权融合, 检索服务异常时回退至本地词法检索; 引入 HR Memory, 记录 JD 修改、候选人入围 / 淘汰与人工调分反馈, 沉淀岗位偏好和筛选阈值规则, 持久化存储并注入后续 Agent 上下文, 支持规则启停与重置。
- 执行可靠性:** 通过 TimeoutDeadline 在阶段内共享模型重试与下游调用的剩余超时预算, 配合指数退避控制重试耗时, 避免各次重试重新占用完整超时时间; 基于持久化任务状态恢复笔试评分、知识导入、海报及汇总报告等特定任务, 通过 WebSocket 推送阶段状态与结果, 并记录 Agent 调用耗时、Token 用量和错误信息, 支持长链路执行追踪与故障定位。